

Clase 7: Ingeniería de características

FM849 - Programación Científica para Proyectos de Inteligencia Artificial (IA)

8 de enero de 2026

Motivación

En general, los datos reales vienen con problemas como:

- ▶ Datos faltantes.
- ▶ Datos desordenados.

Es importante entregar datos no nulos y no repetidos a modelos, ya que estas situaciones pueden crear un sesgo. En esta clase, seguiremos aprendiendo algunas funciones útiles en *pandas* que nos permitirán modificar *DataFrames* y realizar un análisis exploratorio sobre datos tabulares.

Continuación del ejemplo práctico

Vamos a seguir explorando el conjunto de datos que tiene información sobre Pokémon en [Google Colab](#).



Limpieza y preparación de datos

- ▶ Tratamiento de valores faltantes.
 - ▶ Detectar valores NA → `isna()`, `notna()`.
 - ▶ Eliminar valores NA → `dropna()`, `fillna()`.

NA se refiere a valores nulos/no disponibles.

- ▶ Corrección de tipos de datos.
 - ▶ Cambiar el tipo → `astype()`.
 - ▶ Crear fechas → `to_datetime()`.
- ▶ Limpieza básica.
 - ▶ Reemplazar valores → `replace()`.
 - ▶ Identificar y remover duplicados → `duplicated()`, `drop_duplicates()`.

Agregación de datos

- ▶ Cálculo de estadísticas que resumen los datos.
 - ▶ `mean()`, `sum()`, `count()`, `min()`, `max()`, `std()`.
- ▶ Agregación por grupos.
 - ▶ `agg()`.
- ▶ Transformaciones agregadas.
 - ▶ Transformar datos → `transform()`.

Agrupamiento de datos

- ▶ Agrupamiento por variables categóricas.
 - ▶ `groupby()`.
- ▶ Agrupamiento por intervalos.
 - ▶ `cut()`.
 - ▶ `qcut()`.
- ▶ Reestructuración de datos.
 - ▶ `pivot()`, `pivot_table()`.
 - ▶ `melt()`.

Referencias

Wes McKinney. *Python for Data Analysis*. O'Reilly Media, 3 edition, 2022.